# TECHNISCHE UNIVERSITÄT DRESDEN

FAKULTÄT INFORMATIK
INSTITUT FÜR TECHNISCHE INFORMATIK
PROFESSUR FÜR RECHNERARCHITEKTUR
PROF. DR. WOLFGANG E. NAGEL

Komplexpraktikum Paralleles Rechnen - Aufgabe B

Daniel Körsten

## Inhaltsverzeichnis

1	Auf	gabenbeschreibung	2
	1.1	Conway's Game-of-Life	2
	1.2	Besonderheiten der Aufgabenstellung	2
2	lmp	lementierung	3
	2.1	Daten initialisieren	3
	2.2	Berechnung der nächsten Generation	4
		2.2.1 Inneres Feld	4
		2.2.2 Kanten	6
	2.3	Ein und Ausgabe	6
3	Zeit	messung auf Taurus	6
	3.1	Testumgebung	6
	3.2	Testmethode	7
4	Tes	tergebnisse	8
	4.1	GCC kompilierte Version	8
	4.2	ICC kompilierte Version	10
	4.3	Scheduling-Verfahren	12
A	Tab	ellen	15
Lit	teratı	ur	17

## 1 Aufgabenbeschreibung

In dieser Aufgabe soll eine Thread-parallele Version von Conway's Game-of-Life in der Programmiersprache C implementiert werden.

Anschließend soll die Simulation mit verschieden großen Feldgrößen und Compiler durchgeführt und verglichen werden.

#### 1.1 Conway's Game-of-Life

Das Game-of-Life ist ein vom Mathematiker John Horton Conway entworfenes Simulationsspiel [Gar70]. Es basiert auf einem zellulären Automaten. Häufig handelt es sich um ein Zweidimensionales Spielfeld, jedoch ist auch eine Dreidimensionale Simulation möglich.

Das Spiel besteht dabei aus einem Feld mit einer festgelegten, möglichst großen, Anzahl an Zeilen und Spalten. Eine Zelle kann dabei entweder Tot oder Lebendig sein. Dieses Spielfeld wird mit einer zufälligen Anfangspopulation initialisiert.

Ein Sonderfall stellen die Ecken und Kanten des Feldes dar, da dort nach den Spielregeln das Verhalten nicht festgelegt ist. Die Aufgabenstellung gibt vor, dass Spielfeld Torus-förmig sein soll. Alles was das Spielfeld auf einer Seite verlässt, kommt auf der gegenüberliegenden Seite wieder herein.

Anschließend wird durch die Befolgung der Spielregeln die nächste Generation berechnet. Dafür betrachtet man jede Zelle und ihre 8 Nachbarn, um ihre Entwicklung zu berechnen. Es gelten folgende Spielregeln:

- 1. Eine lebende Zelle mit zwei oder drei Nachbarn überlebt in der Folgegeneration.
- 2. Eine lebende Zelle mit vier oder mehr Nachbarn stirbt an der Überpopulation. Bei weniger als zwei Nachbarn stirbt sie an Einsamkeit.
- 3. Jede tote Zelle mit genau drei Nachbarn wird in der nächsten Generation geboren.

Wichtig ist, dass die Folgegenration für alle Zellen berechnet wird und anschließend die aktuelle Generation ersetzt. Es ist also nicht möglich die nachfolgende Generation im Spielfeld der Aktuellen zu berechnen.

#### 1.2 Besonderheiten der Aufgabenstellung

Die Aufgabenstellung gibt vor, dass die Parallelisierung mittels OpenMP erfolgen soll. OpenMP ist eine API, welche es ermöglicht, Schleifen mithilfe von Threads zu parallelisieren [ope18]. Es eignet sich hervorragend für Shared-Memory Systeme, also Systeme, bei denen mehrere Threads auf einen gemeinsamen Hauptspeicher zugreifen.

Weitere Besonderheiten sind:

- Die Simulation soll variabel mit Feldgrößen von 128×128 bis 32768×32768 und 1 bis 32 Threads erfolgen.
- Das OpenMP Schedulingverfahren soll hinsichtlich des Einflusses auf die Ausführungszeit untersucht werden.
- Das Programm soll mit dem dem GCC und ICC kompiliert und anschließend getestet werden.

## 2 Implementierung

Zuerst habe ich mich mit der Abstraktion des Feldes in C beschäftigt. Meine Idee ist die Allokierung eines Speicherbereichs der Größe columns \* rows \* sizeof(u\_int8\_t) durch die C-Funktion malloc(). Innerhalb des Speicherbereichs kann man sich nun frei bewegen. Dabei verwendet man die columns als Offset um an die entsprechende Stelle zu springen. Praktischerweise entspricht eine Zelle im Feld einem Byte im Speicher.

Beispiel: Möchte man auf die Zweite Zelle in der Zweiten Zeile (da die Nummerierung typischerweise bei 0 beginnt, also das erste Element) zugreifen, würde man das columns + 1 Byte innerhalb des Speicherbereichs verwenden.

Der Datentyp u\_int8\_t benötigt dabei nur Ein Byte pro Zelle und ist für die Speicherung mehr als ausreichend, da ich nur den Zustand 0 - Zelle tot und 1 - Zelle lebendig speichern muss. Ein Byte ist typischerweise die kleinste adressierbare Einheit im Speicher. Das ist auch der Grund, warum kein noch kleiner Datentyp möglich ist.

Um zu Berücksichtigen, dass die Folgegeneration immer der aktuelle Generation ersetzt, allokiere ich einen zweiten Speicherbereich gleicher Größe. Vor dem Beginn einer neuen Berechnung, vertausche ich die beide Speicherbereiche, was dazu führt, dass die im vorhergehenden Schritt berechnete Folgegeneration zur aktuellen Generation wird und eine neue Generation berechnet werden kann.

#### 2.1 Daten initialisieren

Gemäß den Startbedingungen muss nur eines der beiden Spielfelder mit Zufallswerten initialisiert werden. Um den Code möglichst einfach und effizient zu halten, verwende ich eine for-Schleife zur Iteration über jede Zelle des Arrays.

Für die Dateninitialisierung jeder Zelle mit Null oder Eins, habe ich mich für Pseudo-Zufallszahlengenerator rand\_r() entschieden. Dieser ist, im Vergleich zu z.B. rand() Thread-sicher und kann Thread-parallel ausgeführt werden.

Für die eigentliche Parallelisierung verwende ich die OpenMP Direktive:

```
#pragma omp parallel for schedule(runtime)
```

Diese bewirkt, dass der Code innerhalb der Schleife parallel ausgeführt wird. OpenMP erzeugt beim betreten zusätzliche *slave* Threads. Jeder bekommt einen Teil der Arbeit zugewiesen und führt diesen unabhängig von den anderen Threads aus. Wenn alle Threads ihre Arbeit erledigt haben, der parallel auszuführende Code also abgearbeitet wurde, fährt der *master* Thread mit der seriellen Ausführung fort, bis er die nächste Direktive erreicht.

Über die Umgebungsvariable OMP\_THREAD\_LIMIT kann ein Thread Limit gesetzt werden. OpenMP verwendet dann maximal so viele Threads, wie angegeben. Wird die Umgebungsvariable nicht gesetzt, verwendet OpenMP eine optimale Anzahl an Threads. Typischerweise entspricht die der Zahl der Anzahl der Hardware-Threads auf dem System.

Durch schedule (runtime) ist es später möglich, über die Umgebungsvariable OMP\_SCHEDULE das Schedulingverfahren zu wählen.

Bei der parallelen Ausführung ist darauf zu achten, dass jeder Thread mit einem unterschiedlich *seed* den Pseudo-Zufallszahlengenerator rand\_r() startet. Um dieses Problem zu lösen, entschied ich mich, die Threads mit der OpenMP Direktive

```
#pragma omp parallel
```

vor der seed Generierung zu erzeugen. Dadurch werden Zwei Probleme gelöst:

- 1. Jeder Thread arbeitet auf seiner eigenen *seed* Variable. Dadurch wird verhindert, dass Threads auf der gleichen Variable arbeiten und folglich ein Flaschenhals entsteht.
- 2. Die *seed* Variablen können unterschiedliche Werte haben, was wiederum die Entropie des initialisierten Spielfeldes erhöht.

Die *seed* Variable ergibt sich bei mir aus der aktuellen Zeit in Sekunden und der Thread ID. Da bei jeder Ausführung die Zeit als auch die Thread ID variiert, erhält jeder Thread einen zufälligen *seed* mit geringem Rechenaufwand.

#### **Anmerkung zu rand\_r():**

rand\_r() wird in den Linux Man Pages als schwacher Pseudo-Zufallszahlengenerator geführt [lmp10]. Das soll an dieser Stelle keine Relevanz haben, da der Spielverlauf und Rechenaufwand nicht von der Güte des Zufallsgenerators abhängt.

Vielleicht Bild, wie so ein initialisiertes Feld aussieht?

#### 2.2 Berechnung der nächsten Generation

Die Berechnung der nächsten Generation erfolgt mithilfe beider Spielfelder.

Die Funktion calculate\_next\_gen () erhält einen Pointer auf das Array mit der aktuellen Generation \*state\_old und einen auf das Array der Folgegeneration \*state.

Bei jedem Simulationsschritt werden Pointer getauscht und die Funktion erneut aufgerufen. Damit wird die Forderung der Aufgabenstellung nach *double buffering* erfüllt, sprich die Folgegeneration in einem separatem Spielfeld berechnet.

Da es sich um ein Torus-förmiges Spielfeld handelt, benötigen die Kanten und Ecken eine separate Behandlung. Den Großteil stellt die Berechnung des inneren Feldes dar. Gleichzeitig unterscheiden sich die Schritte nur unwesentlich.

## 2.2.1 Inneres Feld

Der Zustand der Zelle in der nächsten Generation wird über die Spielregeln bestimmt und ist abhängig vom aktuellen Zustand der Zelle und ihren Acht Nachbarn. Da der Zustand mit Null (tot) oder Eins (lebendig) repräsentiert wird, kann die Zahl der Nachbarzellen aufsummiert werden. Die Summe entspricht dabei der Zahl lebender Nachbarn.

An dieser Stelle könnte mithilfe einer if-Verzweigung der Folgezustand entschieden werden. Allerdings

entschied ich mich für die Verwendung von bitweisen Operatoren. Es handelt sich dabei aus schaltungstechnischer Sicht um die einfachsten Operationen auf den einzelnen Bits.

Der Grund liegt darin, dass die CPU bei *if*-Verzweigungen ihre Sprungvorhersage verwendet um die Pipeline möglichst sinnvoll auszulasten. Selbst mit einer guten Vorhersage werden falsche Entscheidungen getroffen, die dann rückgängig gemacht werden müssen. Gleichzeit ist die CPU sehr schnell im abarbeiten von arithmetischen Operationen.

Daraus ergibt sich, bei der Verwendung bitweiser Operatoren, ein Performance Vorteil.

Im ersten Schritt werden alle Zellen berechnet, die nicht Teil einer Kante sind. Dafür verwende ich zwei geschachtelte for-Schleifen:

```
#pragma omp parallel for schedule(runtime)

for (int i = 1; i < rows - 1; i++) {

    for (int j = 1; j < columns - 1; j++) {

        //count up the neighbours

        u_int8_t sum_of_8 = state_old[(i - 1) * columns + (j - 1)] +

        state_old[(i - 1) * columns + j] +

        state_old[i * columns + (j + 1)] +

        state_old[i * columns + (j - 1)] +

        state_old[(i + 1) * columns + (j - 1)] +

        state_old[(i + 1) * columns + (j - 1)] +

        state_old[(i + 1) * columns + (j + 1)];

        state_old[(i + 1) * columns + (j + 1)];

        state[i * columns + j] = (sum_of_8 == 3) | ((sum_of_8 == 2) & state_old[i * columns + j]);

    }
}
```

Listing 1: Berechnung der inneren Zellen

Die Erste Schleife iteriert dabei über jede Zeile und in jeder Zeile geht die Zweite durch jede Zelle. Ich habe dabei, wie schon bei der Daten Initialisierung, die OpenMP Direktive:

```
#pragma omp parallel for schedule(runtime)
```

#### verwendet.

Dabei wird jedoch nur die äußere Schleife parallelisiert. Das bewirkt, dass die Zeilen jeweils parallel berechnet, jedoch nicht aufgeteilt werden. OpenMP ist in der Lage mit collapse (2) zwei geschachtelte Schleifen zu parallelisieren, indem es daraus eine große Schleife erzeugt. Diese große Schleife wird dann in chunks zerlegt und den einzelnen Threads zur Bearbeitung zugewiesen. In meinen Tests führte dies zu einer enormen Verschlechterung der Performance, weswegen ich es nicht verwendet habe.

Die Gründe dafür können vielfältig sein. Ein Grund könnte der Fakt sein, dass OpenMP die Schleife ungünstig zerlegt.

Für die Berechnung einer Zelle benötigt man die Zelle selbst und ihre Acht Nachbarn. Geht man eine Zelle weiter, benötigt man Sechs der Neun Zellen aus dem vorherigem Schleifendurchlauf. Die Brechungen

überlappen also. Verwendet man für die Berechnung einer Zeile einen Kern (= ein Thread; deaktiviertes Simultaneous Multithreading vorausgesetzt), kann man vom Cache profitieren. Jeder Kern arbeitet dann möglichst auf den Daten, die er schon einmal angefasst hat.

Zum anderen kann der Compiler, bei meiner Implementierung, die innere Schleife modifizieren und so eventuelle Optimierungen vornehmen. Ich habe mir deshalb mit objdump den Quellcode anzeigen lassen, konnte jedoch keine SIMD-Instruktionen finden.

#### 2.2.2 Kanten

Wie bereits erwähnt, unterscheidet sich die Art und Weise der Berechnung der Kanten nur unwesentlich von der des inneren Feldes. Da die Kanten jeweils nur aus einer Zeile bzw. Spalte bestehen, wird nur eine for-Schleife benötigt. Außerdem muss in der Berechnung beachtet werden, dass Felder von der gegenüberliegenden Seite benötigt werden. Auch hier wurden die Kanten wieder mit

```
#pragma omp parallel for schedule(runtime)
```

parallelisiert.

-> Zeitmessung

## 2.3 Ein und Ausgabe

Da die Messung später in verschiedenen Feldgrößen durchgeführt wird, habe ich mich für den Einsatz von getopt entschieden. Es ermöglicht die Anzahl der Schleifendurchläufe, die Feldgröße und eine optionale Fortschrittsanzeige über Argumente beim Programmstart einzustellen. Ebenso lässt sich das Ergebnis visualisieren.

Alle Funktionen, sowie der Syntax lassen sich über den Parameter --help ausgeben.

## 3 Zeitmessung auf Taurus

#### 3.1 Testumgebung

Alle Messungen wurden auf dem Hochleistungsrechner Taurus der TU Dresden durchgeführt.

Verwendet habe ich die Romeo-Partition, die auf AMD Rome EPYC 7702 Prozessoren basiert [Mar21]. Hier reservierte ich für die Messungen einen kompletten Node, um Schwankungen durch andere Prozesse auf dem Knoten auszuschließen. Ein Node ist mit 512 GB RAM ausgestattet. Als Betriebssystem kommt Centos 7 zum Einsatz.

Wie in der Aufgabenstellung gefordert, kompilierte ich das Programm mit dem GCC (GNU Compiler Collection, Version 11.2) und dem ICC (Intel Compiler Collection, Version 19.0.1.144); jeweils mit der Compiler-Flag -fopenmp.

Vor Beginn der Messung muss noch die Topologie des unterliegenden Systems betrachtet werden. Für die optimale Performance soll ein Thread pro Core ausgeführt werden, also kein Simultaneous Multi-threading verwendet werden.

Da ein Romeo Node aus zwei Epyc Prozessoren à 64 Cores besteht, aber das Game-of-Life mit maximal 32 Threads ausgeführt werden soll, sollte die Berechnung außerdem nur auf einem der beiden Prozessoren ausgeführt werden. Dadurch kann das Potenzial des Speichers und der Caches optimal ausgeschöpft werden. Zusätzlich erleichtert es die Umsetzung der *first touch NUMA policy*, deren Befolgung zu einer höheren Ausführungsgeschwindigkeit führt.

Auf Linux wird Speicher mit malloc() nur reserviert, aber nicht im physischen Speicher angelegt. Das geschieht erst beim Zugriff der Threads auf die entsprechenden Speicherbereiche. Würde man dazu Threads auf beiden Sockets ausführen, würde ein Teil des Arrays im physischen Speicher von Socket 0 und der Andere im physischen Speicher von Socket 1 liegen.

Damit wird es kompliziert, denn es muss bei späteren Teilen des Codes, die Thread-parallel ausgeführt werden, sichergestellt werden, dass auf die Teile des Arrays, die physisch an Socket 0 angebunden sind, nur Threads zugreifen, die auch auf Socket 0 ausgeführt werden. Ansonsten müssten die Threads auf nicht lokalen Speicher zugreifen, was Zeit kostet.

Einfacher ist es daher, alle Threads auf einem Socket auszuführen. Um das zu erreichen, verwendete ich die Environment-Variablen:

- OMP\_PLACES=cores ein Thread je Core
- OMP\_PROC\_BIND=close Threads nah nebeneinander platzieren
- OMP\_DISPLAY\_ENV=VERBOSE zur Überprüfung, ob alle Parameter korrekt gesetzt wurden

#### 3.2 Testmethode

Die Tests wurden automatisiert mit einem sbatch-Skript ausgeführt. Um Schwankungen auszugleichen, wurde jede Messung 20 mal wiederholt.

Um herauszufinden, wie lang ein Test durchgeführt werden muss, aber ich einen Messung mit 1 Wiederholung, 32 Threads und einer Feldgröße von 128 durchgeführt. Das stellt die minimale Zeit dar, die das Programm in etwa benötigt, um geladen zu werden, Threads zu spawnen und zu synchronisieren, und lag bei ca. 2 ms. Zur Berücksichtigung dieser Zeit, entschied ich mich, die Messungen mindestens 3 Größenordnungen länger, also mehr als 2 s, auszuführen.

Dabei ist zu beachten, dass die Ausführungszeit (logischerweise) mit der Feldgröße linear ansteigt. Interessanter für das Praktikum ist jedoch das Verhalten bei Thread-paralleler Ausführung. Deshalb passte ich die Anzahl der Wiederholungen an die Feldgröße an. Die genauen Details lassen sich den Tabellen 1 und 2 entnehmen.

Ich entschied mich dabei für einen exponentiellen Anstieg der Wiederholungen. Der Grund dafür ist, dass die Feldgröße ebenfalls exponentiell ansteigt. Damit bleiben die Ausführungszeiten für alle Feldgrößen in etwa konstant.

## 4 Testergebnisse

In diesem Abschnitt habe ich die Messwerte aus den Tabellen A visualisiert.

#### 4.1 GCC kompilierte Version

Zuerst möchte ich auf die GCC kompilierte Version des Spiels eingehen.




Abbildung 1: Logarithmische Darstellung der Ausführungszeit der Funktion calculate\_next\_gen (). Kompiliert mit GCC.

Die gezeigte Grafik berücksichtigt nur die Ausführung der Funktion calculate\_next\_gen(). Da sich sowohl die Feldgröße, als auch die Anzahl der Wiederholungen exponentiell erhöht, bietet sich eine Doppellogarithmische Darstellung an.

Man erkennt eindeutig die zu erwartende Tendenz: Mehr Threads bewirken eine Verkürzung der Laufzeit. Allerdings lässt sich bei den Feldgrößen 128 deutlich und 512 in abgeschwächter Form erkennen, dass ab einer gewissen Thread Anzahl kein Speedup mehr erreicht werden kann. Schlimmer noch: Bei der Größe 128 steigt die Ausführungszeit mit 32 Threads wieder an.

Eine Begründung ist, dass die einzelnen Schleifendurchläufe dieser Feldgrößen sehr schnell abgeschlossen sind. Mit steigender Anzahl an Threads steigt auch der Overhead durch Thread spawning, Synchronisation und Zuteilung der Arbeit. Ab einem gewissen Punkt ist dieser Overhead im Vergleich zum zu

lösenden Problem nicht mehr vernachlässigbar klein und wirkt sich negativ auf den Speedup aus. Wie in allen folgenden Grafiken zeichnet sich schon hier das Bild ab, dass eine Verdopplung der Threads nicht zur Halbierung der Laufzeit führt.

Ein anderes Bild zeichnet sich jedoch beim Ausführen der Funktion field\_initializer() ab.





Abbildung 2: Logarithmische Darstellung der Ausführungszeit der Funktion field\_initializer(). Kompiliert mit GCC.

Erwartungsgemäß benötigt ein großes Feld mehr Zeit zum initialisieren, als ein kleines Feld. Betrachtet man, dass ein 32768 Spielfeld 16 mal so groß ist wie 8192 und nach den Daten auch etwa 16 mal so viel Zeit in Anspruch nimmt, sind die Zeiten sehr plausibel und skalieren etwa linear mit der Feldgröße. Ausnahmen bilden hier wieder die kleinen Feldgrößen, bei denen die Werte auch extrem schwanken. Erklären lässt sich das mit der äußerst kurzen Ausführungszeit von teilweise deutlich unter 10 ms bei einer Feldgröße von 128. Vermutlich ist hier wieder der Overhead im Verhältnis zum zu lösenden Problem deutlich größer. Bei einer großen Problemgröße benötigt die Initialisierung etwa gleich viel Zeit unabhängig von der Zahl der Threads. Die Parallelisierung bietet an dieser Stelle keinen nennenswerten Geschwindigkeitsvorteil. Für kleine Felder ist ein leichter Anstieg zu erkennen, der ähnlich der calculate\_next\_gen() Funktion mit dem entstehenden Overhead erklärbar ist.

#### 4.2 ICC kompilierte Version






Abbildung 3: Logarithmische Darstellung der Ausführungszeit der Funktion calculate\_next\_gen(). Kompiliert mit ICC.

Ähnlich zur GCC kompilierten Version des Spiels sind hier die selben Effekte erkennbar. Mehr Threads verkürzen generell die Ausführungszeit und bei kleinen Feldgrößen verringert sich zunehmend der Speedup.

Auffällig ist, dass die Version des Intel Compilers bei der jeweilig selben Anzahl von Threads und Feldgröße nur ca. 25% der Zeit benötigt. Also zu jeder Zeit etwa vier mal so schnell ist. Der Intel Compiler produziert folglich besser optimierten Code.

Ich habe mir mittels objdump den disassemblierten Code beider Binaries angeschaut, da ich vermutete, dass der Intel Compiler möglicherweise SIMD-Instruktionen verwendet. Das ist jedoch nicht der Fall.




Abbildung 4: Logarithmische Darstellung der Ausführungszeit der Funktion field\_initializer(). Kompiliert mit ICC.

Bei der Dateninitialisierung zeigt sich beim Intel Compiler ein etwas anderes Bild. Im Allgemeinen schwanken die Werte der ICC Version weniger stark.

Bei Feldgrößen ab 2048 ist er ebenfalls schneller als die Version des GCC Compilers. Bei den Werten darunter ist ein Vergleich schwierig, da die Zeiten der GCC Version stark schwanken. Tendenziell lässt sich wieder ein Anstieg der Zeit mit steigender Zahl an Threads verbuchen.

## 4.3 Scheduling-Verfahren

Den letzten Teil der Ergebnisse stellt der Vergleich der Scheduling-Verfahren dar. OpenMP bietet verschiedene Scheduling-Verfahren zur Auswahl. Im Rahmen der Aufgabenstellung betrachte ich

- · guided
- auto
- dynamic
- static

und erhielt die folgenden Messwerte.

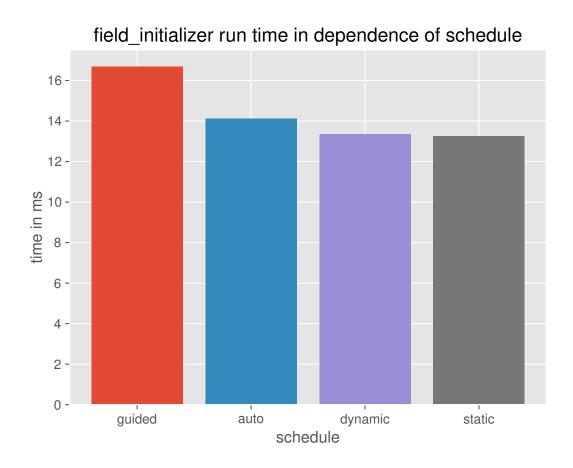


Abbildung 5: Ausführungszeit der Funktion field\_initializer() unter Berücksichtigung des Scheduling-Verfahrens. Kompiliert mit ICC.

Betrachtet man die Zeiten der field\_initializer() Funktion, fallen die Unterschiede sehr gering aus, was auch der kleinen Feldgröße geschuldet ist.




Abbildung 6: Ausführungszeit der Funktion calculate\_next\_gen() unter Berücksichtigung des Scheduling-Verfahrens. Kompiliert mit ICC.

Bei der calculate\_next\_gen () Funktion fallen hingegen deutliche Unterschiede auf. Das Verfahren *static* liefert hier mit Abstand die kürzesten Ausführungszeiten. Um zu erklären warum, ist es sinnvoll, sich die Funktionsweise der Verfahren anzusehen.

Beim *static* schedule garantiert OpenMP, dass mehrere Schleifen mit der selben Anzahl an Iterationen und Threads so unter den Threads aufgeteilt werden, dass jeder Thread bei den Durchläufen den selben Bereich der Iterationen abarbeitet. Im Fall des Game-of-Life also immer auf den selben Zellen arbeitet. Das führt hier natürlich zu einer sehr guten Performance, da Cache und NUMA Eigenschaften optimal ausgenutzt werden. Das *static* Verfahren hat zusätzlich einen geringen Overhead.

Beim *dynamic* schedule gibt es diese feste Aufteilung nicht. Es arbeitet nach dem Prinzip *first come*, *first served* und hat einen höheren Overhead als *static*. Der Vorteil des *first come*, *first served* Prinzips liegt in der guten Systemauslastung (workload balancing), wenn der Berechnungsaufwand der einzelnen Iterationsschritte variiert, da einem Thread einfach neue Arbeit zugewiesen wird, sobald er seine Arbeit beendet hat.

Das das Game-of-Life jedoch einen konstanten Berechnungsaufwand je Iterationsschritt hat, ist dieses Verfahren eher ungeeignet. Das zeigt sich auch in der Ausführungszeit.

Das *guided* Verfahren ist nur ein Spezialfall des *dynamic* schedule. Der Unterschied besteht darin, dass sich die chunk size, also die Anzahl der Iterationen, die ein Thread zur Abarbeitung erhält, mit zunehmenden Fortschritt verkleinert. Entsprechend schneidet das *guided* Verfahren ähnlich schlecht wie *dynamic* ab.

Bei *auto* entscheidet der Compiler und/oder die Laufzeitumgebung über das Scheduling Verfahren [Hag19]. Betrachtet man die Ausführungszeit, ist diese zwar kürzer als *dynamic* und *guided*, erreicht aber mit großem Abstand nicht die Ergebnisse von *static*.

## A Tabellen

Compiler	Size	#Threads	Repetitions	Initialization in s	Calculation in s
GCC			100 000	0.0003	30.7874
GCC			100 000	0.0007	17.171
GCC			100 000	0.0011	9.5063
GCC			100 000	0.0036	6.8678
GCC	128	16	100 000	0.0032	5.4929
GCC	128 32		100 000	0.0038	5.8989
GCC	512		10 000	0.0039	48.383
GCC	512	2	10 000	0.0181	25.4004
GCC	512	4	10 000	0.0147	12.9686
GCC	GCC 512 8 GCC 512 16		10 000	0.0088	7.1592
GCC			10 000	0.0088	4.0574
GCC	512	32	10 000	0.0115	2.6117
GCC	2048	1	1 000	0.0623	77.1689
GCC	2048	2	1 000	0.0791	39.0673
GCC	2048	4	1 000	0.0692	19.6133
GCC	2048	8	1 000	0.1033	10.0464
GCC	2048	16	1 000	0.0971	5.174
GCC	2048	32	1 000	0.1038	2.7467
GCC	8192	1	100	0.9902	125.295
GCC	8192	2	100	1.1225	63.2725
GCC	8192	4	100	1.0953	31.7264
GCC	GCC 8192		100	1.1748	15.8625
GCC	8192	16	100	1.2046	7.9815
GCC	8192	32	100	1.2601	4.0859
GCC	32768	1	10	15.8826	199.181
GCC	32768	2	10	20.1785	100.1272
GCC	32768	4	10	18.0209	50.0713
GCC	32768	8	10	17.1956	25.0854
GCC	32768	16	10	17.4827	12.5836
GCC	32768	32	10	17.7285	6.3286

Tabelle 1: Testergebnisse der GCC kompilierten Version des Game-of-Life. Zeiten gerundet auf vier Stellen.

Compiler	piler Size #Threads		Repetitions	Initialization in s	Calculation in s
ICC			100 000	0.0021	8.5322
ICC	ICC 128 2		100 000	0.0022	4.5041
ICC	128 4		100 000	0.0025	2.5492
ICC	128	8	100 000	0.0035	1.9608
ICC	128	16	100 000	0.0054	1.8089
ICC	CC 128 32		100 000	0.0127	1.9434
ICC	512	1	10 000	0.0061	13.4002
ICC	512	2	10 000	0.0063	6.742
ICC	512	4	10 000	0.0072	3.4289
ICC	512	8	10 000	0.0082	1.7867
ICC	512	16	10 000	0.0099	0.9776
ICC	512	32	10 000	0.0195	0.5929
ICC	2048	1	1 000	0.0496	21.5322
ICC	2048	2	1 000	0.0485	10.7675
ICC	2048	4	1 000	0.052	5.4267
ICC	2048	8	1 000	0.0519	2.7251
ICC	2048	16	1 000	0.0546	1.3692
ICC	2048	32	1 000	0.0638	0.6911
ICC	8192	1	100	0.7441	37.5091
ICC	8192	2	100	0.7437	19.5603
ICC	8192	4	100	0.7483	9.9158
ICC	8192	8	100	0.7696	5.1219
ICC	8192	16	100	0.7756	2.5619
ICC	8192	32	100	0.7851	1.2802
ICC	32768	1	10	11.8049	55.2352
ICC	32768	2	10	11.8445	27.6332
ICC	32768	4	10	11.8567	13.8855
ICC	32768	8	10	12.2583	6.9565
ICC	32768	16	10	12.2543	3.4985
ICC 32768		32	10	12.3533	1.7492

Tabelle 2: Testergebnisse der ICC kompilierten Version des Game-of-Life. Zeiten gerundet auf vier Stellen.

Compiler	Schedule	Size	#Threads	Repetitions	Initialization in s	Calculation in s
ICC	guided	128	32	1 000 000	0.0167	43.4062
ICC	auto	128	32	1 000 000	0.0141	37.5988
ICC	dynamic	128	32	1 000 000	0.0133	39.7113
ICC	static	128	32	1 000 000	0.0133	20.6912

Tabelle 3: Testergebnisse der verschiedenen Scheduling-Verfahren. Zeiten gerundet auf vier Stellen.

#### Literatur

[Gar70] GARDNER, Martin. MATHEMATICAL GAMES - The fantastic combinations of John Conway's new solitaire game "life".

https://web.stanford.edu/class/sts145/Library/life.pdf. 1970

[Hag19] HAGEMEIER, Annika. Einführung in die Parallelprogrammierung.

https://www.fz-juelich.de/ias/jsc/EN/AboutUs/Staff/Hagemeier\_A/docs-parallel-programming/OpenMP-Slides.pdf?\_\_blob=publicationFile. 2019

[lmp10] Linux Man Pages - rand.

https://linux.die.net/man/3/rand.2010

[Mar21] MARKWARDT, Dr. U. Introduction to HPC at ZIH.

https://doc.zih.tu-dresden.de/misc/HPC-Introduction.pdf. 2021

[ope18] OpenMP Application Programming Interface 5.0.

https://www.openmp.org/wp-content/uploads/ OpenMP-API-Specification-5.0.pdf. 2018